

Arquitectura RAG para asistente documental Resumen RAG significa Retrieval-Augmented Generation. Es una arquitectura que combina búsqueda semántica con generación de texto. Primero se recuperan fragmentos relevantes desde una base vectorial y luego el LLM genera una respuesta usando ese contexto. Flujo de procesamiento 1. El usuario sube un PDF. 2. El sistema extrae el texto con un loader. 3. El texto se divide en chunks con solapamiento. 4. Se generan embeddings para cada fragmento. 5. Los embeddings se guardan en ChromaDB. 6. Ante una pregunta, se buscan fragmentos similares y se pasan al LLM como contexto. Componentes Los componentes principales son: PyPDFLoader para leer PDFs, RecursiveCharacterTextSplitter para dividir texto, OllamaEmbeddings con nomic-embed-text para embeddings, ChromaDB como base vectorial y ChatOllama para generar respuestas. Ventajas La arquitectura RAG reduce alucinaciones porque obliga al modelo a responder usando información recuperada del documento. Es muy útil para asistentes internos, soporte técnico, búsqueda en manuales y análisis de documentación empresarial.